OSTRAVSKÁ
UNIVERZITA
PŘÍRODOVĚDECKÁ FAKULTA

UMĚLÁ INTELIGENCE

Implementace RAG pomocí DSPy a LangChain

Autoři: Natálie Rašková, Nela Bulavová, Filip Jína, Martin Šašinka

Obsah

Úvod

V této seminární práci se zaměříme na implementaci RAG modelu (Retrieval-Augmented Generation) pomocí GPT 3.5 TURBO. Budou použity dva frameworky: DSPy a LangChain. Práce zahrnuje jak teoretický popis, tak praktickou aplikaci a vyhodnocení výsledků. Studijní řád OU byl použit jako data pro RAG.

Cíl práce

Cílem této seminární práce je vyzkoušet základní implementaci RAG modelu GPT 3.5 TURBO a pochopit, jak funguje zpracování dokumentů pomocí tohoto modelu. Zaměříme se na praktické aspekty nasazení modelu při práci s textovými dokumenty a na jeho schopnosti při vyhledávání a generování informací.

RAG

RAG (Retrieval-Augmented Generation) je kombinací dvou hlavních přístupů v oblasti umělé inteligence: vyhledávání (retrieval) a generování (generation) textu. RAG je navržen tak, aby zlepšil kvalitu a přesnost odpovědí na dotazy tím, že nejprve vyhledá relevantní informace z externí databáze a poté na základě těchto informací vygeneruje odpověď.

Jak funguje RAG model?

Vyhledávání: Když je položen dotaz, model nejprve prohledá předem definovanou databázi dokumentů a vybere několik nejrelevantnějších úryvků textu.

Generování: Na základě vyhledaných úryvků textu model následně vygeneruje koherentní a informativní odpověď, která odpovídá položenému dotazu.

DSPy

DSPy je rámec pro řešení pokročilých úloh s jazykovými modely (LM) a modely pro vyhledávání (RM). Sjednocuje techniky pro podněcování a dolaďování LM – a přístupy pro uvažování, sebezdokonalování a rozšiřování s vyhledáváním a nástroji (DSPy, *n.d.*).

Použití DSPy s RAG modelem

Naším původním záměrem bylo použít DSPy jako řešení pro implementaci RAG modelu Llama3. Chtěli jsme využít tento framework pro trénování a nasazení lokálního modelu pomocí aplikace Ollama s cílem zpracovávat vlastní dokumenty a zlepšit vyhledávání a generování odpovědí.

Bylo vytvořeno několik programů, tyto programy jsou přiloženy v příloze, které měli zaručit zařazení našich dat do dat modelu. Zde jsme bohužel vždy dospěli s modelem Llama3 ke stejnému výsledku. Parametr Bootstrapped 0 full traces na obrázku 1. má význam, že během daného kola bootstrapingu nebyly úspěšně vytvořeny a ověřeny žádné kompletní sledy kroků (tj. sekvence kroků od vstupu k výstupu). V kontextu modelu RAG to znamená, že model

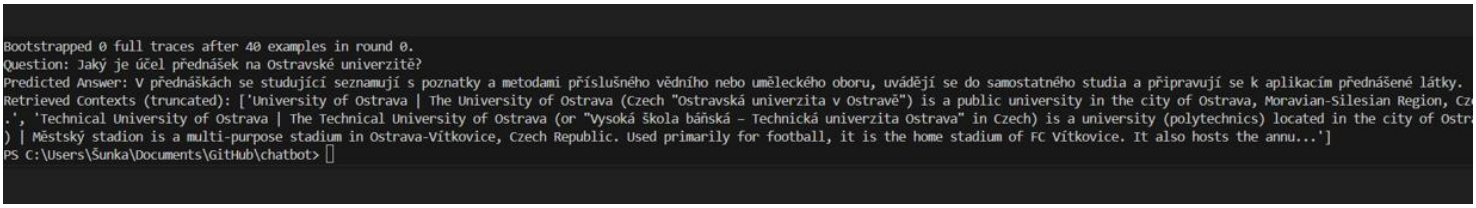

Obrázek 1: DSPy Llama3

nedokázal generovat dostatečně přesné predikce, které by mohly být použity jako nové tréninkové příklady.

Bohužel, tedy pravděpodobně z nedostatku zkušeností a technických znalostí, se nám nepodařilo dosáhnout uspokojivých výsledků. Trénování modelů neprobíhalo podle očekávání a výsledné modely nedosahovaly potřebné úrovně přesnosti a efektivity.

Obdobné výsledky jsme dosáhli po použití modelu GPT 3.5 TURBO, jak je možné vidět na

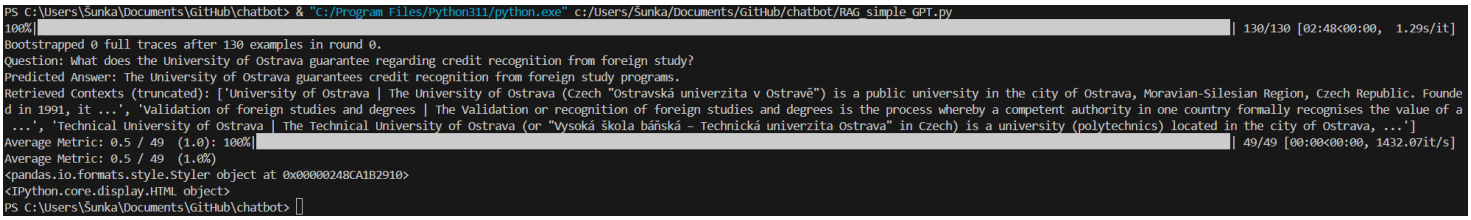

Obrázek 2: DSPy GPT 3.5 TURBO

obrázku 2.

Tento neúspěch nás vedl k hledání alternativních řešení, což nás nakonec přivedlo k použití platformy LangChain.

LangChain

LangChain je framework navržený pro práci s velkými jazykovými modely. Tento framework poskytuje nástroje pro snadnou integraci a správu modelů umělé inteligence, umožňuje vytváření databází a efektivní indexaci dat, což je klíčové pro aplikace jako je RAG.

Použití LangChain s RAG modelem

V našem projektu jsme použili LangChain pro implementaci RAG modelu GPT 3.5 TURBO s cílem zpracovat studijní řád Ostravské univerzity. LangChain nám umožnil:

Vytvoření chroma databáze: Uložili jsme a indexovali vektory z dokumentu studijního řádu, což umožnilo vyhledávání relevantních informací.

Efektivní vyhledávání a generování: LangChain využíval model GPT 3.5 TURBO k vyhledávání a generování odpovědí na základě dotazů, což nám pomohlo při analýze a interpretaci textu studijního řádu.

Evaluace: Provedli jsme hodnocení modelu pomocí metrik jako Score, Precision, Recall a F1-score, abychom posoudili přesnost a účinnost generovaných odpovědí.

Pro spuštění kódu je důležité si zobrazit a postupovat podle souboru README.md

Následující část textu bude popisovat tvorbu vektorové databáze dokumentu, vyhledávání a generování díky OpenAI GPT 3.5 TURBO a Evaluaci našeho RAG.

Vytvoření chroma databáze

1) Příprava dokumentů
- Nejprve jsme extrahovali text z dokumentu studijního řádu.
- Tento text byl následně rozdělen na menší chunky (úseky zpracovatelné LM)
- Na obrázku 3 můžeme nastavit parametry chunk_size (jak jednotlivé chunky budou velké) a chunk_overlap (o kolik se jednotlivé chunky budou překrývat). Tyto parametry nám může výrazně měnit následné vyhledávání a generování v modelu.

```python
def split_text(documents: list[Document]):
    text_splitter = RecursiveCharacterTextSplitter(
        chunk_size=300,
        chunk_overlap=100,
        length_function=len,
        add_start_index=True,
    )
    chunks = text_splitter.split_documents(documents)
    print(f"Split {len(documents)} documents into {len(chunks)} chunks.")

    # Debugging: Print content of some chunks
    for i, chunk in enumerate(chunks[:5]):  # Print first 5 chunks for brevity
        print(f"Chunk {i} content:\n{chunk.page_content[:300]}...\n")
        print(f"Metadata: {chunk.metadata}")

    return chunks
```

-

Obrázek 3: split_text_into_chunks function

2) Generování vektorových reprezentací
- Každý chunk byl převeden na vektorovou reprezentaci (která nám umožní pozdější vyhledávání a indexaci informací)
3) Indexace vektorů
- Vygenerované vektory byly uloženy do chroma databáze. Chroma databáze je speciálně navržena pro ukládání a rychlé vyhledávání vektorových reprezentací.

Vyhledávání a generování

1) Položení dotazu
- Uživatel položí dotaz týkající se informací ve studijním řádu Ostravské univerzity. Tento dotaz je vstupem pro celý proces vyhledávání a generování odpovědí.
2) Vyhledávání relevantních úseků

- LangChain nejprve prohledá chroma databázi, která obsahuje vektorové reprezentace úseků textu z dokumentu studijního řádu.
- Na základě podobnosti vektorů vyhledá nejrelevantnější úseky textu, které odpovídají položenému dotazu. Tím se zajistí, že model pracuje s nejvíce relevantními informacemi.

3) Generování odpovědí
- Model GPT 3.5 TURBO následně zpracuje vyhledané úseky textu a vygeneruje koherentní a informativní odpověď na základě dotazu.

Výsledky námi vyzkoušených promptů se nacházejí v příloze.

Evaluace

Pro zhodnocení výkonu našeho modelu jsme provedli evaluaci pomocí několika klíčových metrik. Tyto metriky nám umožnily posoudit přesnost a účinnost generovaných odpovědí modelu GPT 3.5 TURBO při zpracování dotazů týkajících se studijního řádu Ostravské univerzity. Při evaluaci porovnáváme odpovědi vygenerované modelem s těmi předdefinovanými.

1) Skóre
- Skóre určuje, jak moc jsou vektorové reprezentace odpovědí podobné relevantním úsekům textu.
- Tato metrika využívá různé metody měření podobnosti, jako je kosinová podobnost, která porovnává úhel mezi dvěma vektory v prostoru.
- Vyšší skóre znamená vyšší podobnost, a tedy větší relevanci odpovědi.
- Skóre se může určit například Kosínovou podobností
- $$\text{Kosínová podobnost} = \frac{\vec{A} \cdot \vec{B}}{\|\vec{A}\| \|\vec{B}\|}$$

2) Precision (Přesnost)
- Precision měří, jaký podíl odpovědí vygenerovaných modelem je relevantní.
- $$\text{Precision} = \frac{\text{Počet správných relevantních odpovědí}}{\text{Celkový počet vygenerovaných odpovědí}}$$

3) Recall (Úplnost)
- Recall měří, jaký podíl všech relevantních odpovědí model správně identifikoval.
- $$\text{Recall} = \frac{\text{Počet správných relevantních odpovědí}}{\text{Celkový počet relevantních odpovědí v dokumentu}}$$

4) F1-score
- F1-score je průměr hodnot precision a recall. Tato metrika poskytuje vyvážené měřítko výkonu modelu, zohledňující jak přesnost, tak úplnost.
- $$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Výstup evaluací lze opět najít v příloze

Budoucí práce

1) Optimalizace modelu
- Dále optimalizovat trénovací postupy a nastavení modelů pro dosažení lepších výsledků.
- Experimentovat s různými hyperparametry a technikami trénování pro zlepšení výkonu.
2) Zlepšení evaluace
- Použití pokročilejších metod evaluace a zahrnutí dalších metrik pro přesnější hodnocení výkonu modelů.
- Vytvoření většího souboru testovacích dotazů pro robustnější evaluaci.
3) Uživatelské rozhraní
- Navržení a implementace intuitivního uživatelského rozhraní pro interakci s modelem a databází.
- Poskytnutí nástrojů pro snadné zadávání dotazů a získávání odpovědí.
4) Vyzkoušení dalších frameworků pro RAG
- Experimentování s dalšími frameworky pro implementaci RAG modelů, jako jsou Haystack, Pyserini, nebo ElasticSearch.
- Srovnání jejich výkonu a efektivity s LangChain a DSPy.
5) Možnosti fine-tuningu s modelem
- Provedení fine-tuningu modelu GPT 3.5 TURBO na specifické datové sadě studijního řádu pro dosažení lepšího přizpůsobení a vyšší přesnosti odpovědí.
- Vyzkoušení různých metod fine-tuningu a jejich vliv na výkon modelu při zpracování dotazů.

Závěr

Tato seminární práce se zaměřila na implementaci a evaluaci RAG modelu GPT 3.5 TURBO pomocí frameworků DSPy a LangChain s cílem zpracovat a analyzovat dokumenty, konkrétně studijní řád Ostravské univerzity. Nejprve jsme se pokusili využít DSPy pro trénování a nasazení lokálních modelů, avšak nedosáhli jsme uspokojivých výsledků, pravděpodobně kvůli nedostatku zkušeností nebo nedostatku kapacity modelu pracovat s českým jazykem. Následně jsme použili LangChain, který umožnil vytvoření chroma databáze pro efektivní ukládání a indexování vektorů z dokumentů. Tento přístup zlepšil vyhledávání a generování odpovědí na dotazy. Evaluace pomocí metrik jako Score, Precision, Recall a F1-score ukázala, že LangChain je efektivní platforma pro práci s GPT 3.5 TURBO. Projekt poskytl cenné poznatky o praktické implementaci RAG modelů, identifikoval oblasti pro další optimalizaci a rozšíření, a podtrhl význam technických znalostí při práci s pokročilými AI frameworky.

Citace

DSPy. *Qdrant.tech* [online]. [cit. 2024-06-05]. Dostupné z: https://qdrant.tech/documentation/frameworks/dspy/

Seznam Obrázků